Strojové učení

Cvičení 1 - Práce s daty

Jaroslav Zvoníček

26. září 2026

Obsah

1 Úkol č. 1 **2**

2 Úkol č.2 a č.3 **4**

3 Úkol č. 4 **6**

4 Úkol č. 5.1 **8**

5 Úkol č. 5.2 **10**

6 Úkol č. 5.3 **11**

ÚKOL 1

Úkol č. 1

Zadání: Zobrazte graf s četnostmi žánrů her mezi lety 1990 (včetně) a 2000 (vyjma).

Zdrojový kód

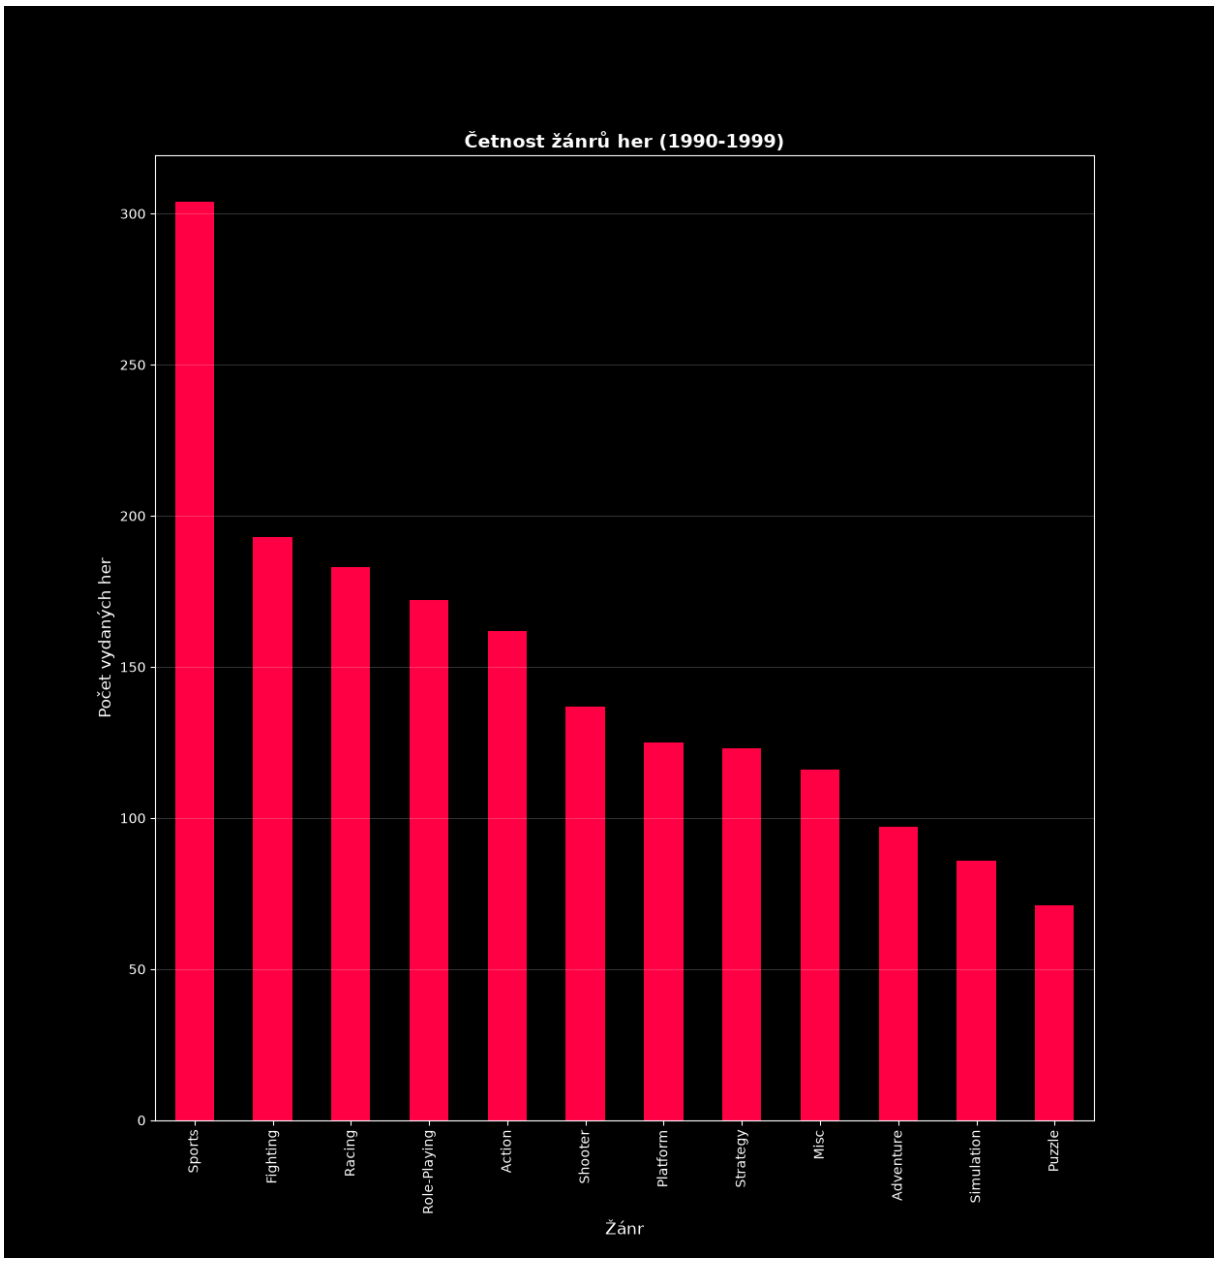
```
1  import numpy
2  import matplotlib.pyplot as plt
3  import pandas as pd
4
5  plt.style.use('dark_background')
6
7  df = pd.read_csv("vgsales.csv")
8
9  df_1990_2000_year = df[(df['Year'] >= 1990)&(df['Year']< 2000)]
10
11 zanry_pocet = df_1990_2000_year['Genre'].value_counts().plot(kind='
       bar', color = '#ff0044')
12
13
14 plt.title("Cetnost zanru her (1990-1999)", fontsize = 14, fontweight
       = 'bold')
15 plt.xlabel('Zanr', fontsize = 12)
16 plt.ylabel('Pocet vydanych her', fontsize = 12)
17 plt.grid(axis='y', alpha = 0.2)
18 plt.show()
```

Vysvětlení kódu

Řádky 9:
Vytvoření DataFramu pouze od konkrétních let.

Řádek 11:
Následně spočítání všech typů žánrů mezi těmito lety

Výstupní graf



Obrázek 1.1: Graf četnosti žánrů her mezi lety 1990 včetně a 2000 (vyjma).

ÚKOL 2

Úkol č.2 a č.3

Zadání: Najděte korelační koeficient mezi prodeji v NA a EU. Hodnota: 0.767727. Zobrazte v grafu korelační koeficient (NA vs. EU) v jednotlivých letech od roku 1985 po rok 2010. viz. obr2.

Zdrojový kód

```
1  import numpy
2  import matplotlib.pyplot as plt
3  import pandas as pd
4
5  plt.style.use('dark_background')
6
7  df = pd.read_csv('vgsales.csv')
8  df_eu_sales = df['EU_Sales']
9  df_na_sales = df['NA_Sales']
10
11 korelace = df_eu_sales.corr(df_na_sales)
12 print(f"Korelacni faktor je: {korelace:.6f}")
13
14 df_obodi_1985_2010 = df[(df['Year'] >= 1985) & (df['Year'] <= 2010)]
15
16 korelace_rozdelene = df_obodi_1985_2010.groupby('Year').apply(lambda
       x : x['NA_Sales'].corr(x['EU_Sales'])).plot(style='o', color = '
       #00ffcc')
17
18 plt.title('Korelace mezi jednotlivymi roky (1985-2010)', fontsize =
       14, fontweight = 'bold')
19 plt.xlabel('Roky', fontsize = 12)
20 plt.ylabel('Korelace', fontsize = 12)
21 plt.grid(axis='y', alpha = 0.2)
22 plt.show()
```

Vysvětlení kódu

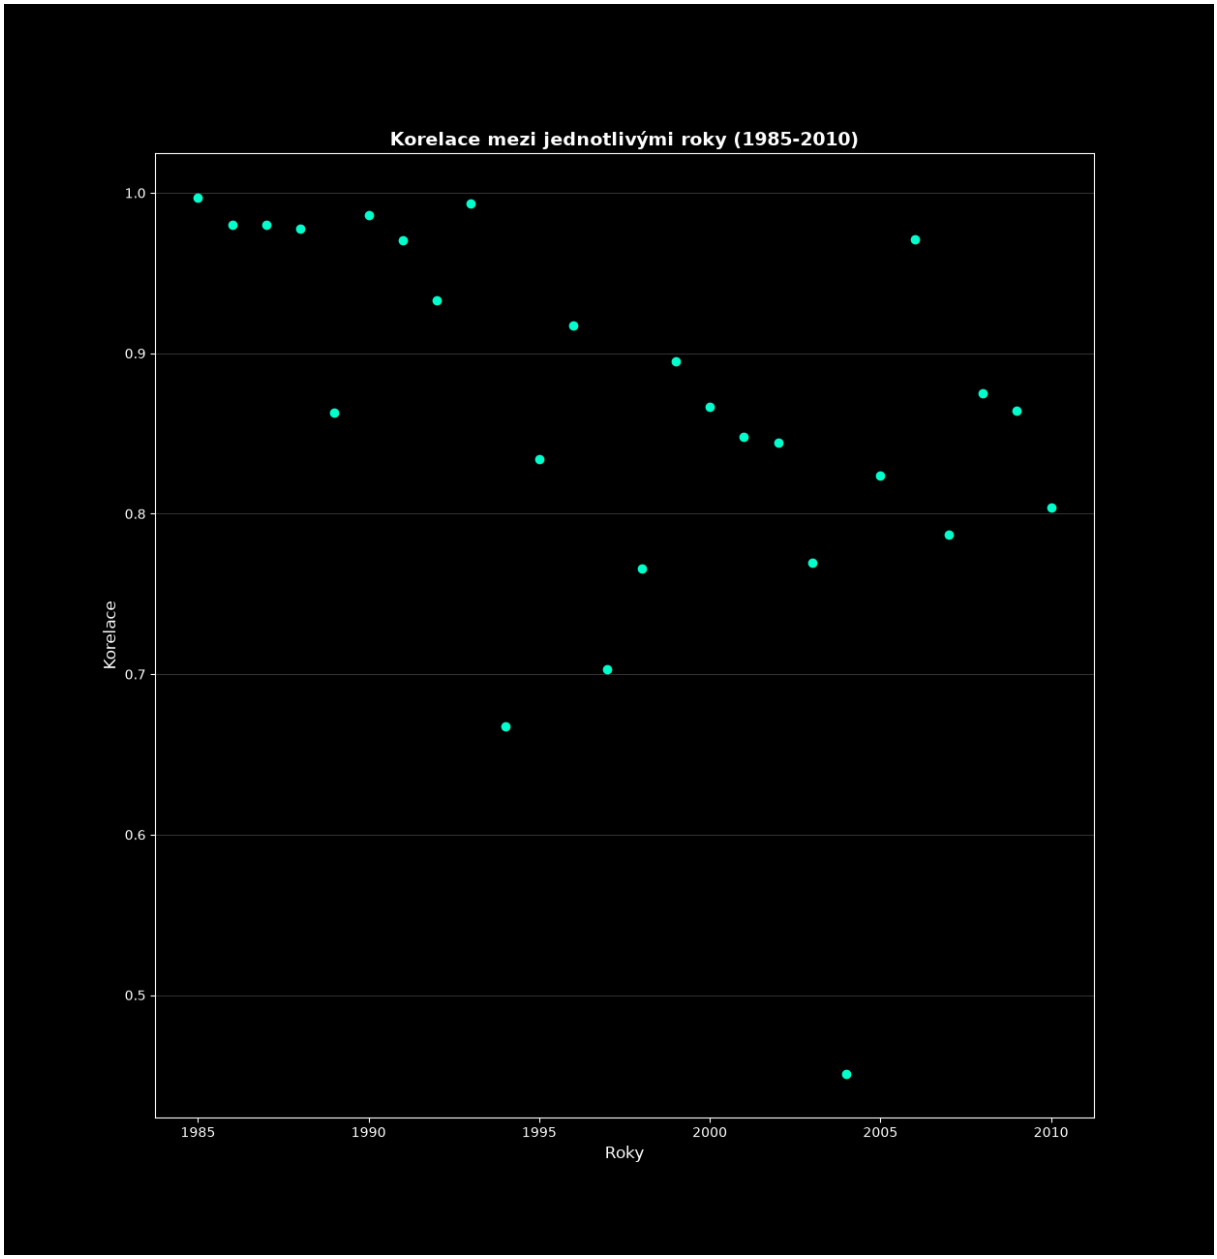
Řádky 11:
Využití funkce korelace z knihovny pandas, která provede korelaci mezi daty eu_sales a na_sales.

Řádek 14:
Vyfiltrování správného časového intervalu, viz. zadání.

Řádek 16:
Pomocí funkce groupby() opět po jednom vytvoříme tabulky a následně vypočítáme

konkrétní korelace pro jednotlivé roky, rozděleně a ne jako celek. Výpočet proběhne pomocí lambda funkce, kde tedy proběhne korelace mezi jednotlivými daty z NA_Sales a z EU_Sales.

Výstupní graf



Obrázek 2.1: Korelace mezi jednotlivými roky

ÚKOL 3

Úkol č. 4

Zadání: Jaké jsou základní statistické údaje rozdílu v prodejích NA a EU pro žánr "Sports", u minima a maxima zjistěte o jaké hry se jedná - minimum (-4.95, FIFA 16), maximum (12.47, Wii Sports), průměr (0.130648), směrodatná odchylka (0.548157).

Zdrojový kod

```
1  import numpy
2  import matplotlib.pyplot as plt
3  import pandas as pd
4
5  df = pd.read_csv("vgsales.csv")
6
7  df_sports = df[df['Genre'] == 'Sports'].copy()
8  df_sports['NA_EU_rozdil'] = df_sports['NA_Sales'] - df_sports['
       EU_Sales']
9
10 rozdil = df_sports['NA_EU_rozdil']
11
12 prumer = rozdil.mean()
13 odchylka = rozdil.std()
14 minimum = rozdil.min()
15 maximum = rozdil.max()
16
17 min_hra = df_sports.loc[rozdil.idxmin(), 'Name']
18 max_hra = df_sports.loc[rozdil.idxmax(), 'Name']
19
20
21 print("! Vypis hodnot !")
22 print(f"Prumer: {prumer:.6f}")
23 print(f"Odchylka: {odchylka:.6f}")
24 print(f"Maximum u {max_hra} s: {maximum:.2f}")
25 print(f"Minimum u {min_hra} s: {minimum:.2f}")
```

Vysvětlení kódu

Řádek 7:
Vytvoření df pouze pro jediný žánr sport.

Řádek 8:
Provedeme rozdíl v prodejech.

Řádek 12-15:
Provedeme na tomto rozdílu matematické operace, příslušné zadání.

Řádek 17-18:

Najdeme příslušný název hry, s minimem a s maximem.

ÚKOL 4

Úkol č. 5.1

Zadání: Detekce anomálií pomocí Z-skóre pro EU trh. Pomocí vztahu pro Z-skóre: (hodnota-průměr)/směrodatná odchylka. Cíl je najít o kolik směrodatných odchylek se evropské prodeje odchylují od průměru.

Zdrojový kód

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import pandas as pd
4
5  df = pd.read_csv("vgsales.csv")
6
7  eu_prumer = df["EU_Sales"].mean()
8  eu_odchylka = df["EU_Sales"].std()
9  df['EU_Z_Score'] = (df['EU_Sales'] - eu_prumer)/ eu_odchylka
10
11 anomalie = df[df['EU_Z_Score'] > 10]
12 anomalie.set_index('Name')['EU_Z_Score'].plot(kind='bar', color ='#00
       ffcc')
13 print(anomalie[['Name', 'EU_Sales', 'EU_Z_Score']])
14
15 plt.show()
```

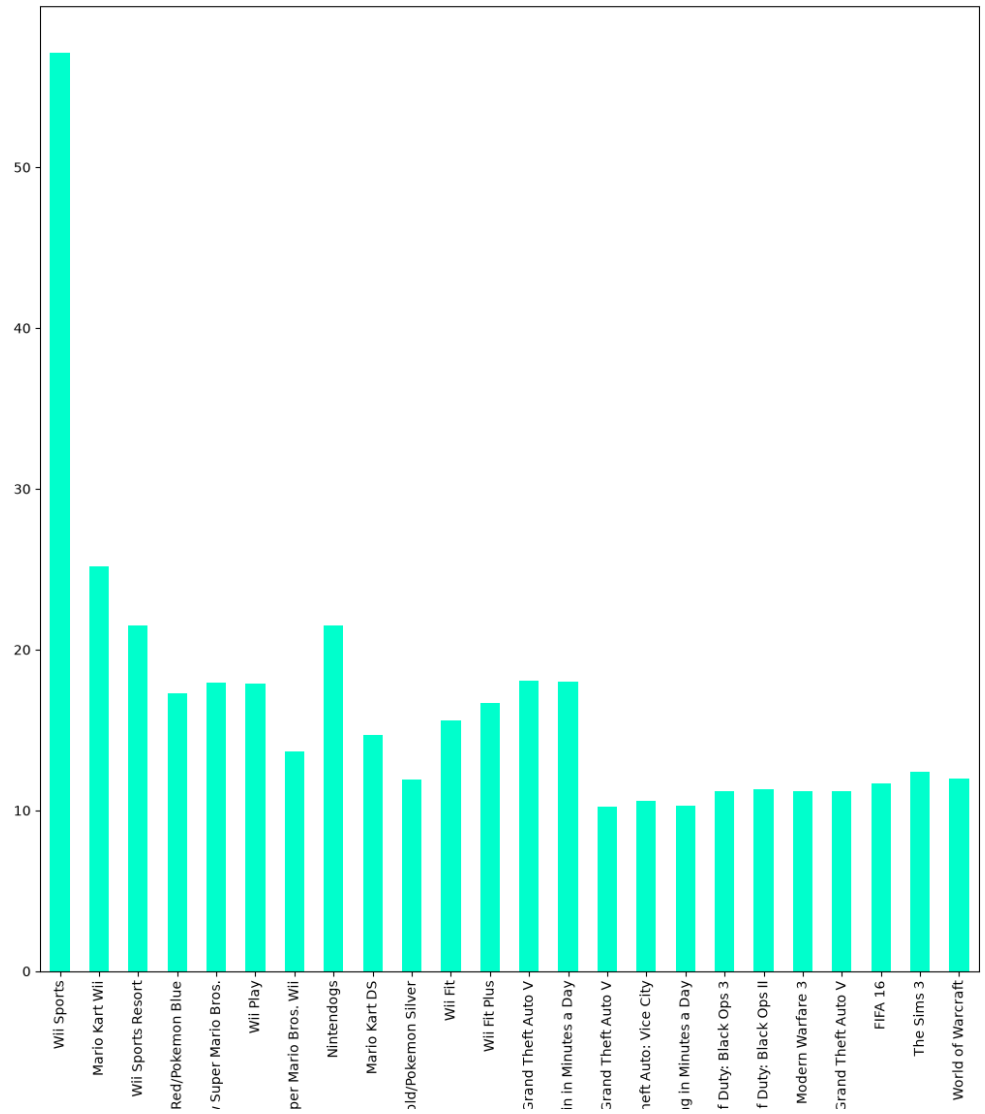
Vysvětlení kódu

Řádek 9:
Výpočet Z-skóre podle vztahu ze zadání.

Řádek 11:
Filtrace Z-skóre většího než 10.

Řádek 12:
Kombinace knihovny pandas a matplotlibu k grafickému vykreslení Z-skóre.

Výstupní graf



Obrázek 4.1: Vizualizace Z-skóre

ÚKOL 5

Úkol č. 5.2

Zadání: Ověření Paketova pravidla na trhu her. Výpočet pomoci kumulativního součtu a podíly celků. Cílem zjistit jaké procento vydavatelů generuje 80 % veškerých globálních prodejů.

Zdrojový kód

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import pandas as pd
4
5  df= pd.read_csv('vgsales.csv')
6
7  soucet_vydavetelu = df.groupby('Publisher')['Global_Sales'].sum().
       sort_values(ascending=False)
8
9  hranice_80 = soucet_vydavetelu.sum()*0.8
10 komulativni = soucet_vydavetelu.cumsum()
11 top_vydavatele = komulativni[komulativni <= hranice_80]
12 print(len(top_vydavatele))
```

Vysvětlení kódu

Řádek 7:

Opět funkce grupby() rozseká jednu celkovou tabulku na menší (přesněji co jeden unikátní vydavatel). Následně se v této jedné hromádce díváme do Global Sales. Následně je sečteme a seřadíme je sestupně.

Řádek 9:

Převedení na procenta.

ÚKOL 6

Úkol č. 5.3

Zadání: Meziroční procentuální růst celosvětového trhu. Vypocet : (soucasny rok - predchozi rok) / predchozi rok. Zjistit jaký rok zaznamenal největší procentuální narůst prodejů global sales oproti předchozímu roku

Zdrojový kód

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import pandas as pd
4
5  df = pd.read_csv('vgsales.csv')
6
7  seskupeni_podle_roku = df.groupby('Year')['Global_Sales'].sum().
       sort_index()
8
9  mezirocni_rust = seskupeni_podle_roku.pct_change()
10 nejvetsi_rust_rok = mezirocni_rust.idxmax()
11 hodnota_rustu = mezirocni_rust.max()*100
12
13 print(f"Nejvetsi narust byl v roce {nejvetsi_rust_rok:.0f} a to o {
       hodnota_rustu:.1f} %.")
```

Vysvětlení kódu

Řádek 7:
Opět rozdělení na malé tabulky. Následně sečeme globals sales a seřadíme je podle indexu.

Řádek 9:
Konkrétní vztah.