Strojové učení

Predikce srážek

Autor: Jaroslav Zvoníček

Datum: 16. října 2026

Obsah

1 Cíl práce a přehled experimentu **2**

1.1 Přehled vytvořených souborů . . . 2

1.2 Datová sada . . . 2

1.3 Postup vyhodnocení a předzpracování . . . 2

2 Matematický základ klasifikátorů **3**

2.1 k-nearest neighbors (kNN) . . . 3

2.2 Gaussian Naive Bayes (GNB) . . . 3

2.3 Použité klasifikační metriky . . . 3

3 Experiment I: Darwin **4**

3.1 Výběr vstupních atributů . . . 4

3.2 Výsledky kNN . . . 4

3.3 Výsledky GaussianNB . . . 4

3.4 Porovnání kNN a GNB pro lokaci Darwin . . . 5

4 Experiment II: Sydney **7**

4.1 Vstupní atributy a směry větru . . . 7

4.2 Výsledky kNN . . . 7

4.3 Výsledky GNB . . . 8

4.4 Porovnání kNN a GNB . . . 9

5 Experiment III: Perth **10**

5.1 Vstupní atributy a sezónnost . . . 10

5.2 Výsledky kNN . . . 10

5.3 GaussianNB . . . 12

5.4 Porovnání kNN a GaussianNB . . . 13

6 Souhrnné porovnání a výběr modelu **13**

6.1 Volba nejvhodnějšího klasifikátoru . . . 14

1 Cíl práce a přehled experimentu

Cílem práce bylo porovnat dva klasifikační algoritmy: k-nearest neighbors (kNN) a Gaussian Naive Bayes (GNB). Celkem jsem vytvořil šest samostatných Python skriptů, tři pro kNN a tři pro GNB. Algoritmy jsem vždy porovnával ve dvojici na datech jednoho města a se stejnými vstupními atributy. Vybral jsem Darwin, Sydney a Perth. U každého města jsem navíc vyzkoušel trochu jiný způsob výběru nebo zpracování atributů.

1.1 Přehled vytvořených souborů

Skript	Lokalita	Atributy	Použité vstupní atributy
`k_neigh_Darwin.py`	Darwin	11	11 základních meteorologických atributů
`GaussianNaiveBayes_Darwin.py`	Darwin	11	11 základních meteorologických atributů
`k_neigh_Sydney.py`	Sydney	17	doplnění cyklického kódování směru větru
`GaussianNaiveBayes_Sydney.py`	Sydney	17	doplnění cyklického kódování směru větru
`k_neigh_Perth.py`	Perth	13	doplnění cyklického kódování měsíce
`GaussianNaiveBayes_Perth.py`	Perth	13	doplnění cyklického kódování měsíce

Tabulka 1: Přehled šesti experimentálních programů.

1.2 Datová sada

Cílová proměnná `RainTomorrow` nabývá hodnot `Yes` (následující den pršelo) a `No` (následující den nepršelo). Řádky s neznámou cílovou hodnotou byly odstraněny. Záměrně jsem nepoužil atribut `RISK_MM`, protože obsahuje informaci o srážkách následujícího dne. Model by tak dostal část informace o výsledku dopředu, a hodnocení by nebylo poctivé. Stejně tak jsem jako vstup nepoužíval samotnou cílovou proměnnou.

1.3 Postup vyhodnocení a předzpracování

Ve všech šesti programech jsem použil desetinásobnou křížovou validaci. Data se rozdělí na deset částí a v každém opakování se jedna část použije k ověření modelu a zbývajících devět k trénování.

Chybějící numerické hodnoty jsem doplňoval mediánem. Mediány se vždy vypočítaly pouze z trénovací části daného foldu a stejným způsobem se pak upravila i testovací část. U kNN jsem následně použil `MinMaxScaler`, aby atributy s větším číselným rozsahem zbytečně nedominovaly ve výpočtu vzdálenosti. Také minima a maxima se počítala pouze z trénovacích dat. GaussianNB jsem používal bez Min-Max škálování.

U kNN jsem vyzkoušel $k \in \{1, 3, 5, 7, 9, 11\}$. Pro každé k jsem uložil průměrné hodnoty accuracy, precision, recall a F1-score z deseti foldů a souhrnnou konfuzní matici. Jako nejlepší k jsem vybral variantu s nejvyšším průměrným F1-score.

2 Matematický základ klasifikátorů

2.1 k-nearest neighbors (kNN)

Algoritmus kNN klasifikuje nové pozorování podle k nejbližších vzorků z trénovacích dat. V tomto případě mají sousedé stejnou váhu a výslednou třídu určuje většinové hlasování. Parametr k tedy určuje, kolik sousedů se do rozhodování zapojí. Pro dva vstupní vektory $\mathbf{x}, \mathbf{z} \in \mathbb{R}^d$ byla použita eukleidovská vzdálenost

$$d(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{j=1}^{d} (x_j - z_j)^2}. \tag{1}$$

Menší k může být citlivější na jednotlivá pozorování, zatímco větší k bere v úvahu širší okolí. Proto jsem nevybral jedno k předem, ale několik hodnot porovnal.

2.2 Gaussian Naive Bayes (GNB)

Gaussian Naive Bayes je pravděpodobnostní klasifikátor vycházející z Bayesova pravidla. U každého numerického atributu předpokládá normální rozdělení podmíněné třídou a podmíněnou nezávislost atributů:

$$P(Y = c \mid \mathbf{x}) \propto P(Y = c) \prod_{j=1}^{d} p(x_j \mid Y = c), \tag{2}$$

$$p(x_j \mid Y = c) = \frac{1}{\sqrt{2\pi\sigma_{jc}^2}} \exp\left(-\frac{(x_j - \mu_{jc})^2}{2\sigma_{jc}^2} \right). \tag{3}$$

Z trénovacích dat se odhadne pravděpodobnost každé třídy $P(Y = c)$ a pro jednotlivé atributy také průměry μ_{jc} a rozptyly σ_{jc}^2. Model následně porovná pravděpodobnostní skóre tříd `Yes` a `No`. Předpoklad podmíněné nezávislosti je zjednodušení: například teploty měřené během jednoho dne spolu mohou souviset.

2.3 Použité klasifikační metriky

Za pozitivní třídu jsem zvolil `Yes`, tedy že následující den pršelo. V konfuzní matici značí TP správně rozpoznaný déšť, TN správně rozpoznaný den bez deště, FP falešný poplach a FN přehlédnutý deštivý den. Použité metriky jsou:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{4}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \tag{5}$$

$$\text{Recall} = \frac{TP}{TP + FN}, \tag{6}$$

$$F_1 = 2\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{7}$$

3 Experiment I: Darwin

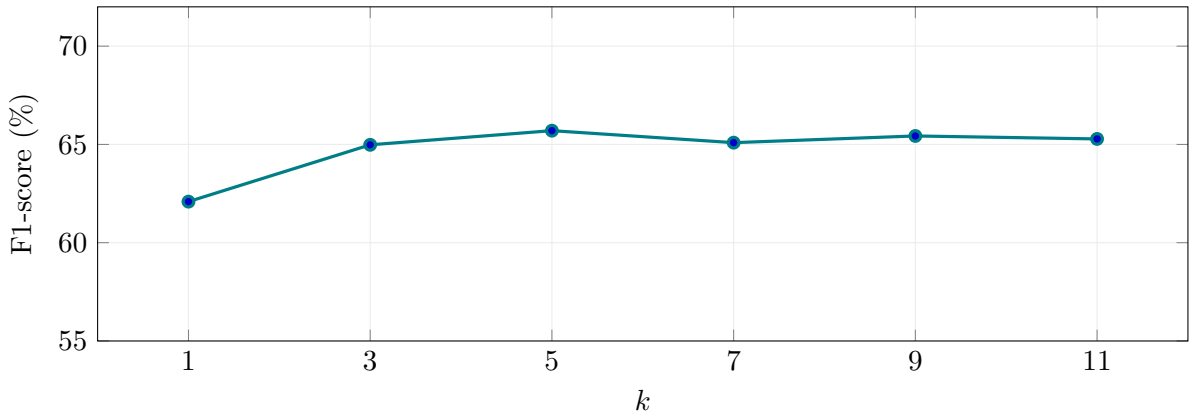
3.1 Výběr vstupních atributů

Pro Darwin bylo použito 11 numerických atributů: `MinTemp`, `MaxTemp`, `Rainfall`, `Humidity9am`, `Humidity3pm`, `Pressure9am`, `Pressure3pm`, `WindSpeed9am`, `WindSpeed3pm`, `Temp9am` a `Temp3pm`. Tomuto experimentu odpovídají skripty `k_neigh_Darwin.py` a `GaussianNaiveBayes_Darwin.py`.

3.2 Výsledky kNN

k	Accuracy (%)	Precision (%)	Recall (%)	F1 (%)
1	80.14	63.34	61.03	62.09
3	82.46	69.82	60.92	64.98
5	83.33	73.02	59.98	**65.70**
7	83.02	72.06	59.52	65.09
9	83.43	74.17	58.93	65.43
11	83.43	74.03	58.57	65.28

Tabulka 2: Darwin: průměrné metriky kNN. Nejlepší k podle F1 je $k = 5$.

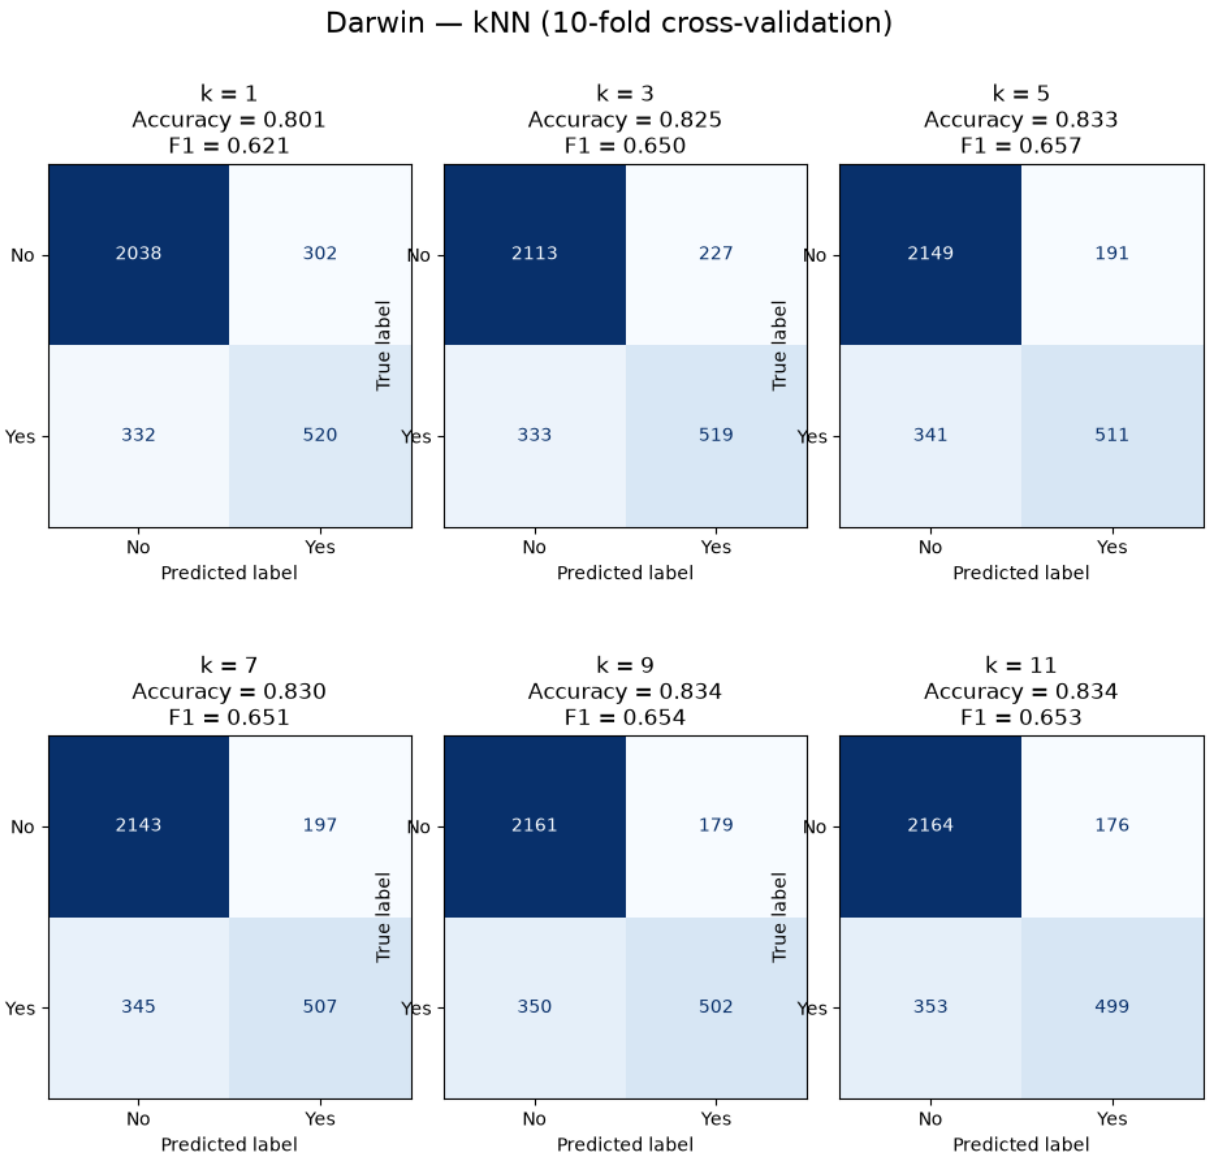


Obrázek 1: Darwin: závislost průměrného F1-score na počtu sousedů.

3.3 Výsledky GaussianNB

Metrika	GaussianNB
Accuracy (%)	82.58
Precision (%)	64.99
Recall (%)	75.58
F1-score (%)	69.83

Tabulka 3: Darwin: GaussianNB

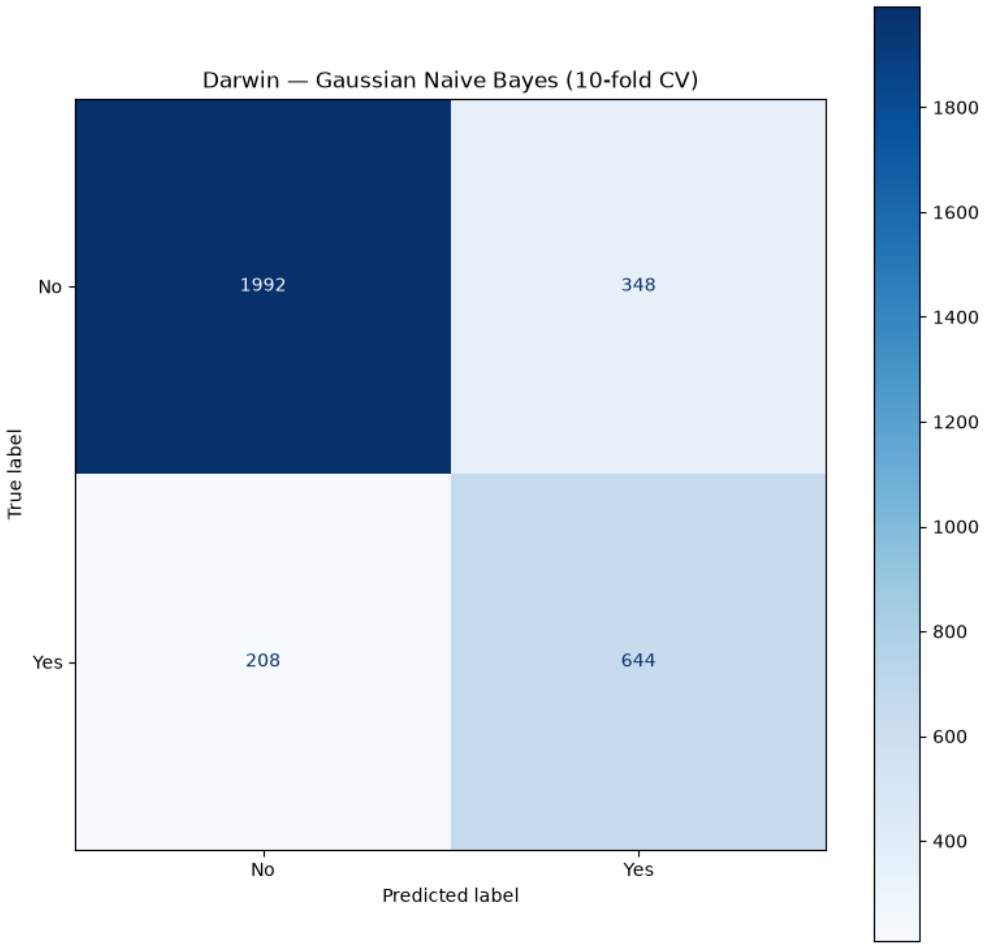


Obrázek 2: Konfuzní matice kNN pro Darwin (11 atributů)

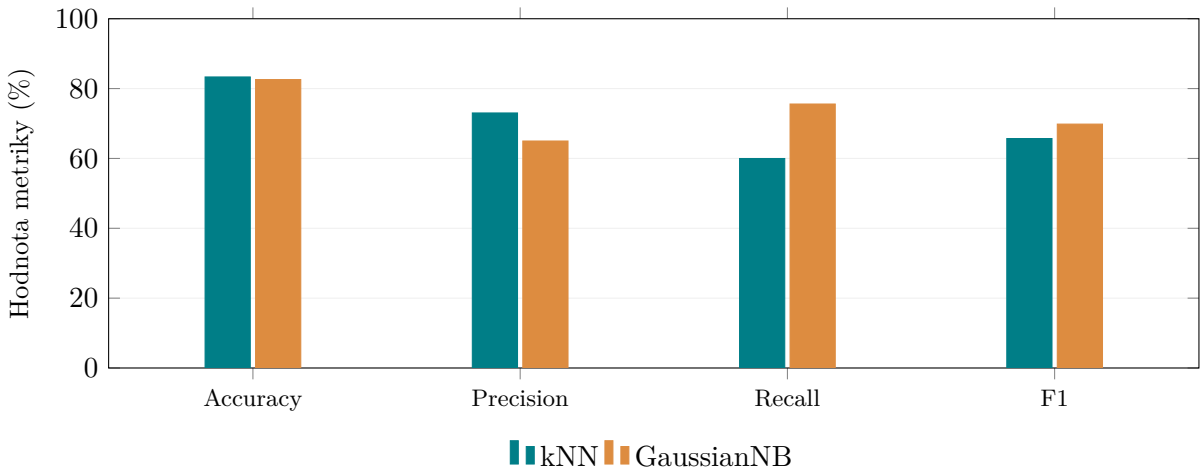
3.4 Porovnání kNN a GNB pro lokaci Darwin

Metrika	kNN ($k = 5$)	GaussianNB
Accuracy (%)	83.33	82.58
Precision (%)	73.02	64.99
Recall (%)	59.98	**75.58**
F1-score (%)	65.70	**69.83**

Tabulka 4: Darwin: porovnání modelů.



Obrázek 3: Konfuzní matice GNB pro Darwin (11 atributů)



Obrázek 4: Darwin: srovnání průměrných metrik.

Výsledek srovnání Záleží na tom, co od předpovědi očekáváme. Podle accuracy vyšel o něco lépe kNN (83,33 % proti 82,58 %). Pokud ale nechceme přehlédnout den, kdy bude pršet, je vhodnější GNB. Jeho recall je 75,58 %, zatímco u kNN je to 59,98 %. GNB tedy rozpoznal větší podíl deštivých dní, ale zároveň má nižší precision.

4 Experiment II: Sydney

4.1 Vstupní atributy a směry větru

Pro Sydney bylo využito 3337 pozorování a 17 numerických atributů. K původním 11 meteorologickým veličinám bylo přidáno šest souřadnic reprezentujících tři směry větru (`WindGustDir`, `WindDir9am`, `WindDir3pm`). Chybějící původní kategorie byly doplněny nejčastější hodnotou z trénovacího foldu. Poté byly kategorie převedeny na azimutální úhly a kódovány pomocí

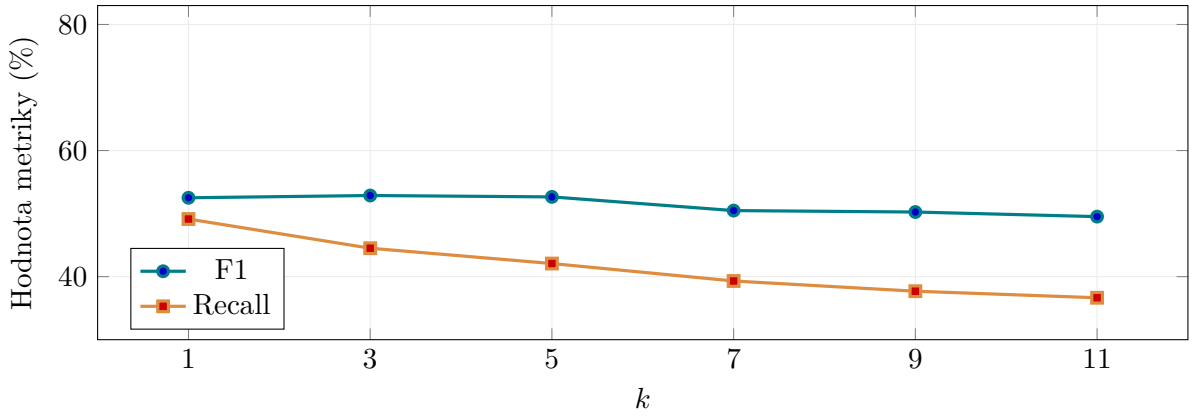
$$(\sin\theta, \cos\theta), \qquad \theta = \frac{\pi}{180}\,\theta_{\text{deg}}. \tag{8}$$

Díky tomu jsou například směry `N` (0°) a `NNW` (337,5°) v novém prostoru blízko sebe. Kdybych použil jen samotné číslo úhlu, kNN by jejich vzdálenost vyhodnotil zavádějícím způsobem. Použité soubory jsou `k_neigh_Sydney.py` a `GaussianNaiveBayes_Sydney.py`. U GNB je přitom potřeba počítat s tím, že složky sinus a kosinus nejsou nezávislé, což úplně neodpovídá jeho předpokladům.

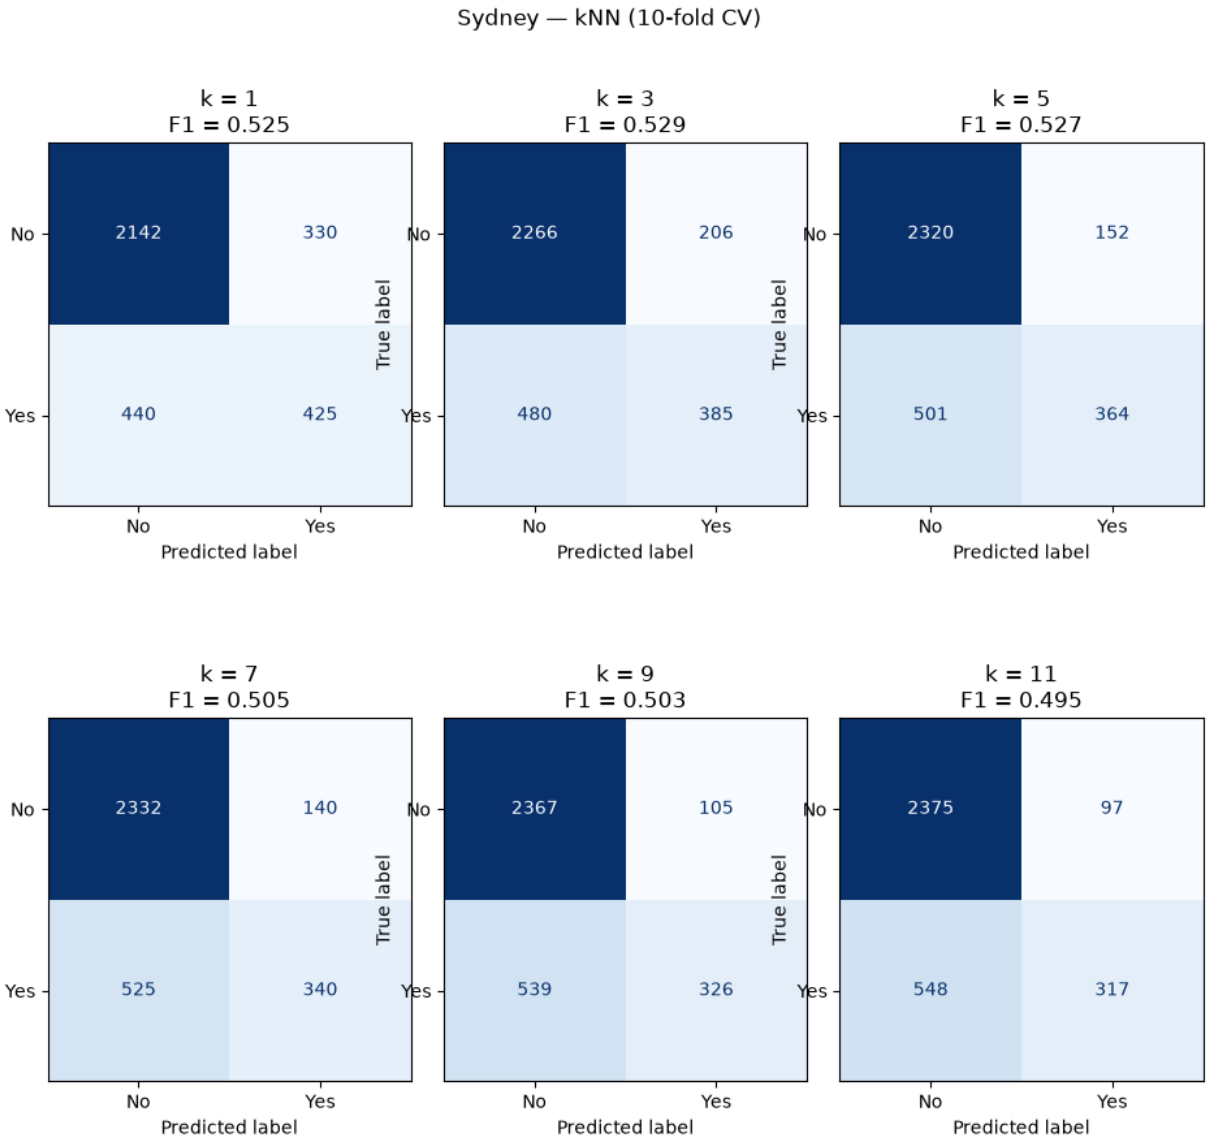
4.2 Výsledky kNN

k	Accuracy (%)	Precision (%)	Recall (%)	F1 (%)
1	76.93	56.72	49.14	52.51
3	79.44	65.66	44.51	**52.87**
5	80.43	70.80	42.08	52.65
7	80.07	71.16	39.31	50.48
9	80.70	76.06	37.69	50.25
11	80.67	77.22	36.65	49.52

Tabulka 5: Sydney: průměrné metriky kNN; Nejlepší k podle F1 je $k = 3$.



Obrázek 5: Sydney: pokles recall s rostoucím k

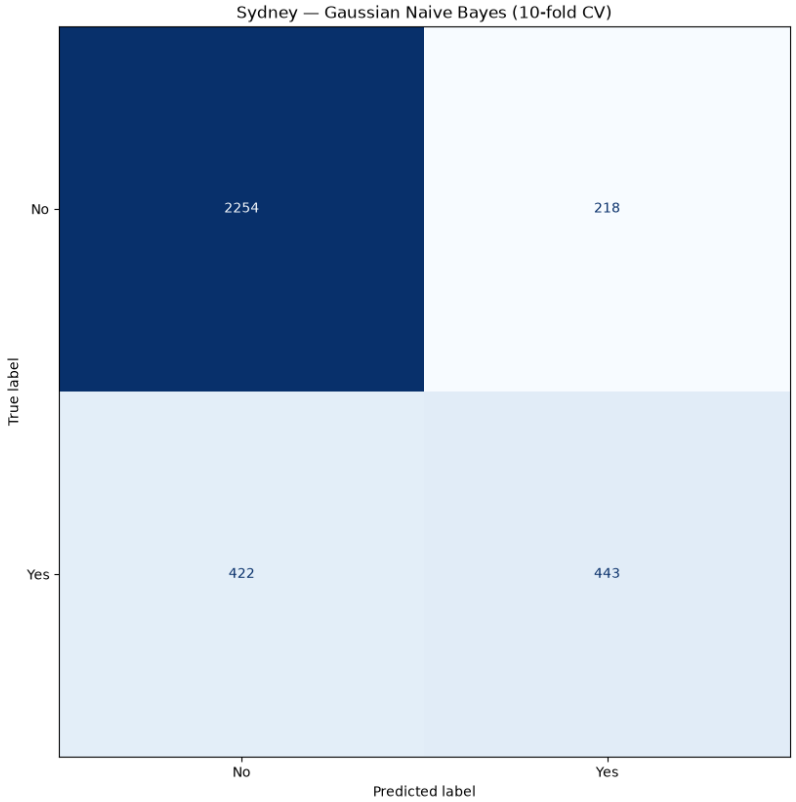


Obrázek 6: Konfuzní matice kNN pro Sydney (17 atributů včetně směru větru)

4.3 Výsledky GNB

Metrika	GaussianNB
Accuracy (%)	80.82
Precision (%)	67.23
Recall (%)	51.22
F1-score (%)	58.06

Tabulka 6: Sydney: GaussianNB

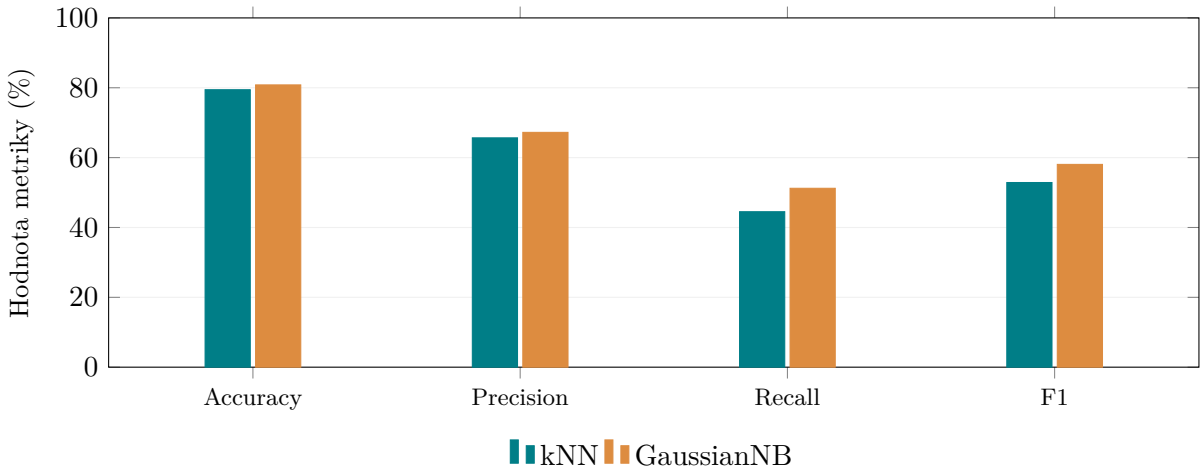


Obrázek 7: Konfuzní matice GNB pro Sydney (17 atributů)

4.4 Porovnání kNN a GNB

Metrika	kNN ($k = 3$)	GaussianNB
Accuracy (%)	79.44	**80.82**
Precision (%)	65.66	**67.23**
Recall (%)	44.51	**51.22**
F1-score (%)	52.87	**58.06**

Tabulka 7: Sydney: Porovnání modelů



Obrázek 8: Sydney: srovnání průměrných metrik.

Výsledek porovnání Pro Sydney dosáhl GNB vyššího průměru u všech čtyř metrik než vybrané kNN s $k = 3$. Největší rozdíl je u recall (51,22 % proti 44,51 %), takže GNB lépe zachytává deštivé dny. Nelze ale říct, že zlepšení způsobilo jen přidání směru větru oproti Darwinu, protože porovnáváme i jinou lokalitu.

5 Experiment III: Perth

5.1 Vstupní atributy a sezónnost

Pro Perth bylo použito 3193 pozorování a 13 příznaků. Jedenáct základních meteorologických atributů bylo rozšířeno o sezónní informaci z datumu. Měsíc $m \in \{1, \ldots, 12\}$ byl převeden na cyklické souřadnice:

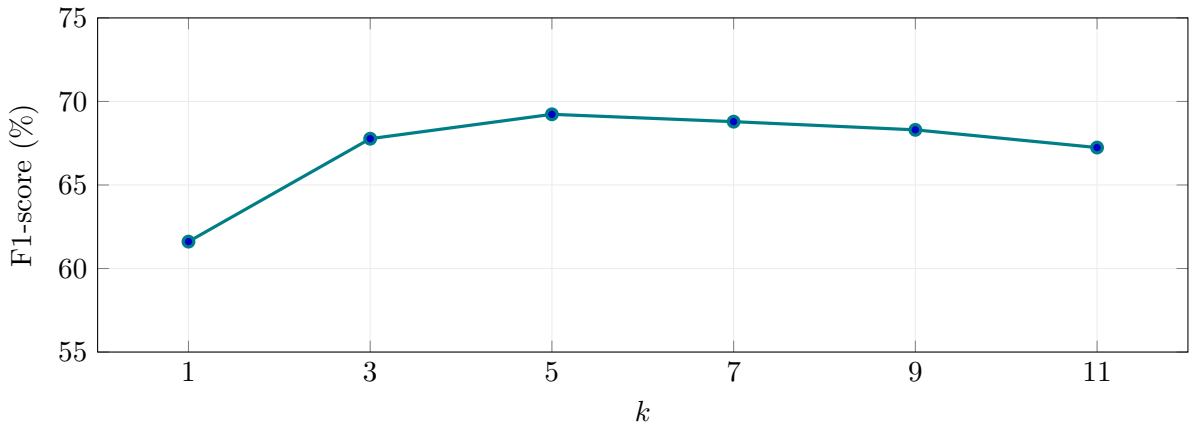
$$\theta_m = \frac{2\pi(m-1)}{12}, \qquad (m_{\sin}, m_{\cos}) = (\sin\theta_m, \cos\theta_m). \tag{9}$$

Leden a prosinec jsou tak na jednotkové kružnici sousedními pozicemi. Transformace je deterministická a nevyžaduje odhad parametrů z celé datové sady.

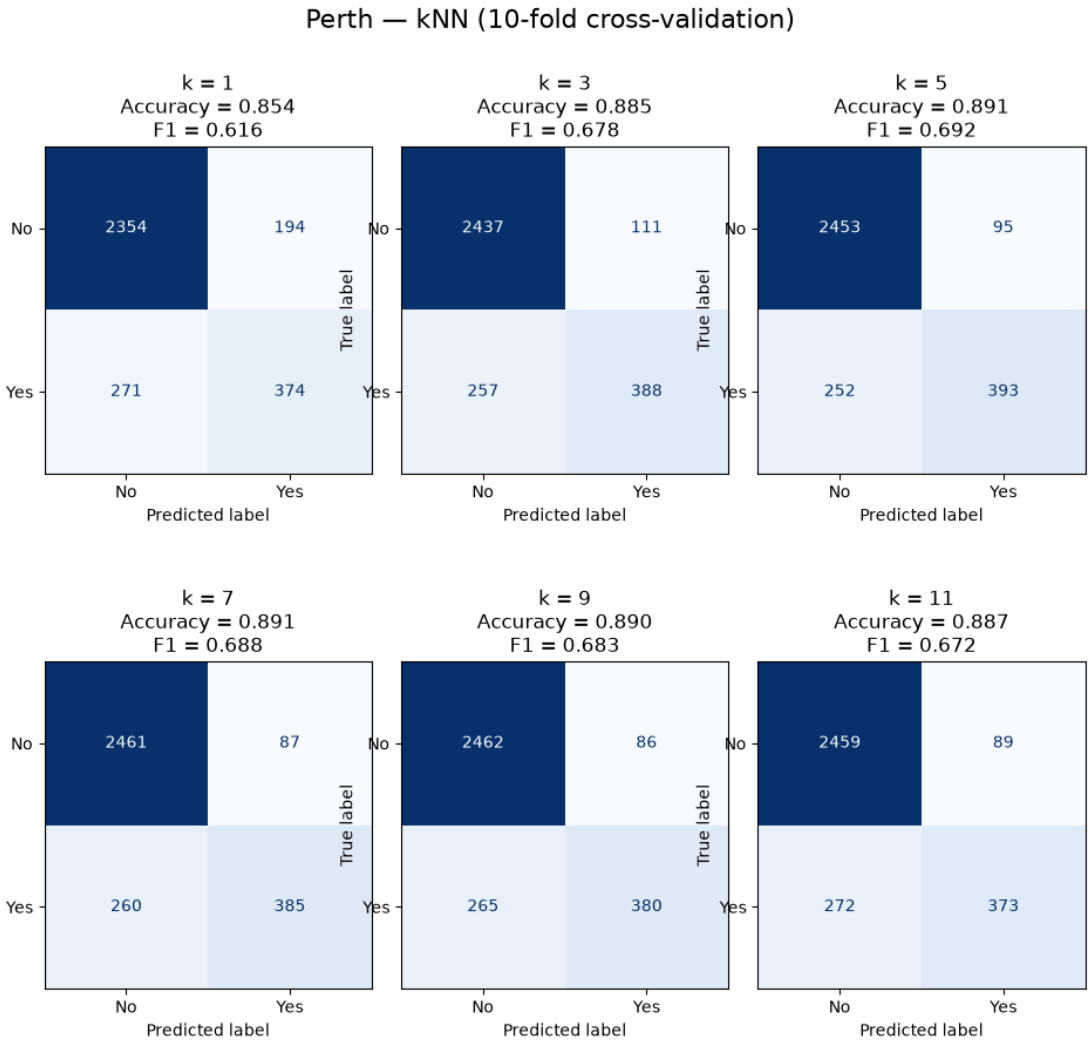
5.2 Výsledky kNN

k	Accuracy (%)	Precision (%)	Recall (%)	F1 (%)
1	85.44	65.95	58.00	61.61
3	88.48	77.95	60.16	67.77
5	**89.13**	80.55	**60.96**	**69.23**
7	89.13	81.68	59.71	68.79
9	89.01	81.76	58.93	68.30
11	88.69	80.84	57.85	67.24

Tabulka 8: Perth: průměrné metriky kNN. Nejlepší k podle F1 je $k = 5$.



Obrázek 9: Perth: nejvyšší F1-score bylo dosaženo při $k = 5$.

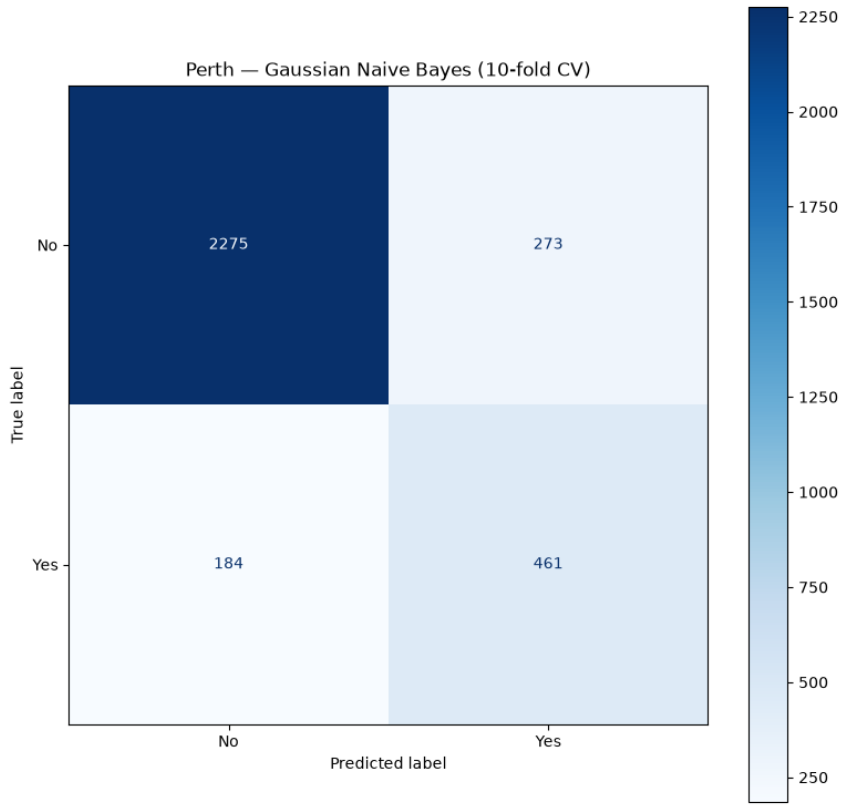


Obrázek 10: Konfuzní matice kNN pro Perth (13 atributů)

5.3 GaussianNB

Metrika	GaussianNB
Accuracy (%)	85.69
Precision (%)	62.84
Recall (%)	71.47
F1-score (%)	66.80

Tabulka 9: Perth: GaussianNB

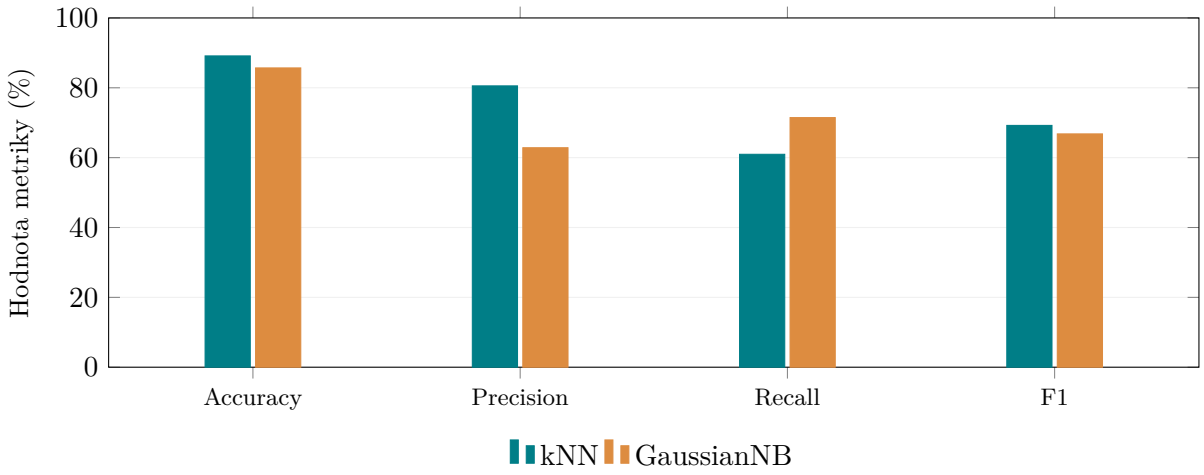


Obrázek 11: Konfuzní matice GNB pro Perth (13 atributů)

5.4 Porovnání kNN a GaussianNB

Metrika	kNN ($k = 5$)	GaussianNB
Accuracy (%)	**89.13**	85.69
Precision (%)	**80.55**	62.84
Recall (%)	60.96	**71.47**
F1-score (%)	**69.23**	66.80

Tabulka 10: Perth: Porovnání modelů



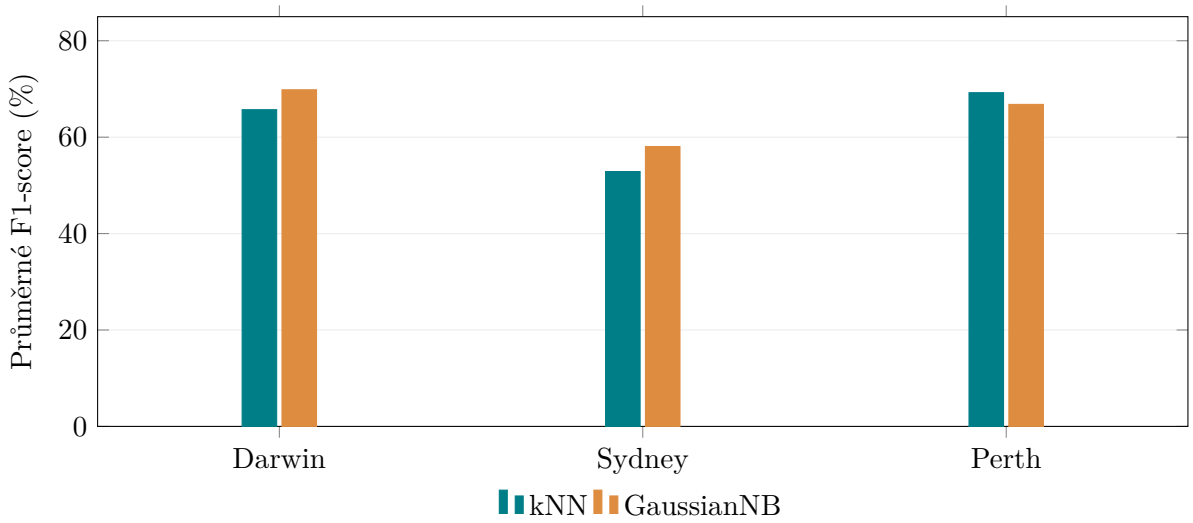
Obrázek 12: Perth: srovnání průměrných metrik.

Výsledek porovnání V Perthu dosáhl kNN s $k = 5$ lepšího F1-score (69,23 %) i accuracy (89,13 %). GNB měl ale opět vyšší recall (71,47 %). Pokud nám více vadí přehlédnutý déšť, dává smysl uvažovat o GNB. Jestli je důležitější omezit falešné předpovědi deště, vychází zde lépe kNN.

6 Souhrnné porovnání a výběr modelu

Lokalita	Model	Accuracy	Precision	Recall	F1
Darwin	kNN ($k = 5$)	83.33	73.02	59.98	65.70
Darwin	GaussianNB	82.58	64.99	75.58	**69.83**
Sydney	kNN ($k = 3$)	79.44	65.66	44.51	52.87
Sydney	GaussianNB	80.82	67.23	51.22	**58.06**
Perth	kNN ($k = 5$)	89.13	80.55	60.96	**69.23**
Perth	GaussianNB	85.69	62.84	71.47	66.80

Tabulka 11: Celkové výsledky v procentech; zvýrazněno nejvyšší F1-score v každé lokalitě.



Obrázek 13: Celkové porovnání šesti modelů podle F1-score.

6.1 Volba nejvhodnějšího klasifikátoru

Pokud jako hlavní kritérium zvolíme *nejvyšší průměrné F1-score*, nejvyšší hodnoty ze všech šesti experimentů dosáhl **GaussianNB pro Darwin (69,83 %)**. Výsledek je však jen mírně vyšší než F1-score kNN v Perthu (69,23 %). Rozdíl je malý a sám o sobě nedokazuje statisticky významnou převahu modelu. Navíc se jednotlivé experimenty liší lokalitou i částečně použitými atributy. Pro praktické použití je vhodné vybírat především model *pro konkrétní lokalitu* a konkrétní požadovanou metriku.

Pokud chceme zachytit co nejvíce deštivých dní, nejvyšší recall v těchto experimentech vykázal GNB v Darwinu (75,58 %). Nejvyšší accuracy měl kNN v Perthu (89,13 %). Za nejrozumnější závěr proto považuji vybírat klasifikátor zvlášť pro každou lokalitu a podle toho, jaký druh chyby nám nejvíce vadí.