TECHNICKÁ ZPRÁVA • STROJOVÉ UČENÍ

Detekce jazyka pomocí znakové n-gramové frekvenční analýzy

Pravděpodobnostní klasifikátor pěti přirozených jazyků

Autor: Jaroslav Zvoníček **Datum:** 31. října 2026

1 Úvod a cíl

Cílem práce bylo vytvořit vlastní klasifikátor rozpoznávající češtinu, slovenštinu, angličtinu, ruštinu a ukrajinštinu. Metoda využívá rozdílů ve frekvencích posloupností znaků, nikoli hotový model pro rozpoznávání jazyka. Součástí řešení je sběr textů, n-gramová analýza, vizualizace a experimentální ověření.

2 Teoretický základ

2.1 Jazyk jako statistické rozdělení znaků

Nechť $x = x_0 x_1 \cdots x_{m-1}$ je normalizovaný text délky m. *Znakový n-gram* je souvislý úsek n znaků počínající na pozici i:

$$g_i^{(n)} = x_i x_{i+1} \cdots x_{i+n-1}, \qquad 0 \le i \le m-n, \quad n \in \{1,2,3\}. \tag{1}$$

Pro text `ababa` vznikají čtyři bigramy `ab`, `ba`, `ab`, `ba`. Počet možných počátečních pozic je $T_n = m - n + 1$ pro $m \ge n$; počet *různých* n-gramů může být nižší.

Každý jazyk L charakterizujeme empirickým rozdělením:

$$\widehat{P}_n(g \mid L) = \frac{C_{L,n}(g)}{T_{L,n}}, \qquad T_{L,n} = \sum_{h} C_{L,n}(h), \tag{2}$$

kde $C_{L,n}(g)$ označuje počet výskytů n-gramu g v daném korpusu. Normalizované četnosti zachovávají rozdíly v užívání písmen, jejich sousedství i *mezer na hranicích slov*.

2.2 Bayesova inference a klasifikační rozhodnutí

Klasifikovaný jazyk chápeme jako neznámou hypotézu $L \in \mathcal{L}$ a náhodně vybrané n-gramy jako pozorovanou evidenci G. Bayesova věta popisuje aktualizaci pravděpodobnosti jazykové hypotézy po pozorování G:

$$\underbrace{P(L \mid G)}_{\text{posterior}} = \frac{\overbrace{P(G \mid L)}^{\text{věrohodnost}}\ \overbrace{P(L)}^{\text{prior}}}{\sum_{L' \in \mathcal{L}} P(G \mid L')P(L')}, \tag{3}$$

kde $P(L)$ je apriorní pravděpodobnost jazyka a $P(G \mid L)$ věrohodnost vybraných znakových vzorů v tomto jazyce. Naivní Bayesův předpoklad nahrazuje společnou věrohodnost součinem četností jednotlivých příznaků:

$$P(G \mid L) \;\approx\; \prod_{n=1}^{3} \prod_{g \in S_n(x)} \widetilde{P}_n(g \mid L), \tag{4}$$

kde $S_n(x)$ obsahuje N vybraných n-gramů řádu n. Při stejných priorech $P(L)$ pro všech pět jazyků lze rozhodnutí učinit porovnáním *logaritmických skóre*:

$$\widehat{L}(x) = \arg\max_{L \in \mathcal{L}} \underbrace{\sum_{n=1}^{3} \sum_{g \in S_n(x)} \ln \widetilde{P}_n(g \mid L)}_{s(L|x)} \tag{5}$$

Logaritmus převádí násobení velmi malých hodnot na jejich sčítání, a tím omezuje numerické podtečení.

Implementační aproximace. Pro nepozorovaný n-gram (0) se používá pevná náhradní hodnota $\widetilde{P}_n(g \mid L) = \varepsilon = 10^{-8}$; pro pozorované n-gramy platí $\widetilde{P}_n = \widehat{P}_n$.

3 Trénovací data a implementace

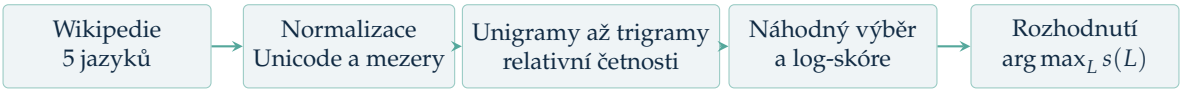
Texty byly získány prostřednictvím MediaWiki API z pěti jazykových verzí Wikipedie. Pro každou jazykovou třídu byl vytvořen samostatný korpus. Velikosti před normalizací zachycuje tabulka 1.

Tabulka 1: Velikost trénovacích korpusů

Jazyk	Kód	Znaky	Slova
Čeština	cs	209 747	31 239
Slovenština	sk	223 068	32 135
Angličtina	en	216 360	34 767
Ruština	ru	212 391	28 029
Ukrajinština	uk	220 791	29 262
Celkem		**1 082 357**	**155 432**

Předzpracování používá Unicode NFC, `casefold()` a nahrazení nepísmenných znaků mezerami. Opakované mezery se sloučí, diakritika i cyrilice zůstávají zachovány. Pro $n = 1, 2, 3$ vznikají slovníky relativních četností ve tvaru `modely[jazyk][n][gram]`.

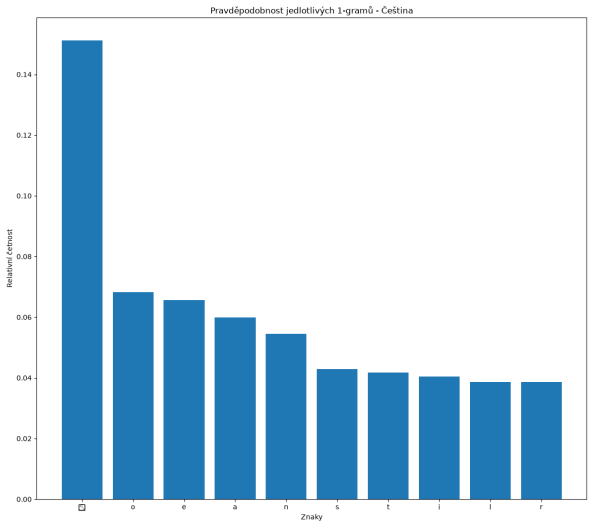
Při klasifikaci se pomocí `random.sample()` vybere N náhodných počátečních pozic pro každý řád; stejná počáteční pozice se nesmí opakovat napříč řády. Vybrané n-gramy se hodnotí ve všech pěti modelech podle rovnice (5). Implementace využívá Python, `requests`, `Counter`, NumPy, Matplotlib a `scikit-learn` pouze pro konfuzní matici.



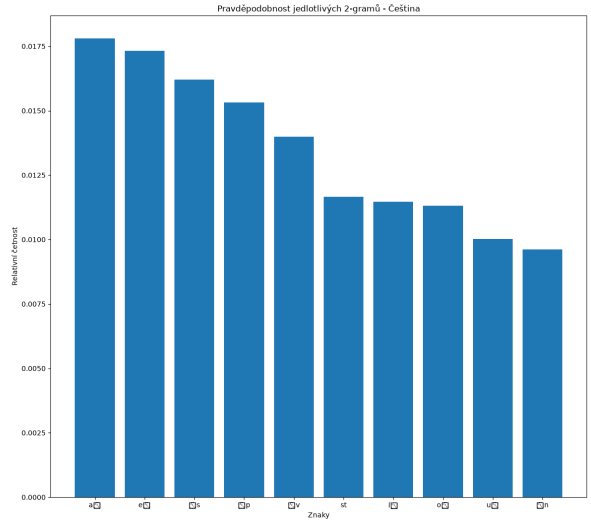
Obrázek 1: Schéma zpracování: příprava jazykových modelů a následná klasifikace textu

4 Frekvenční charakteristiky

Obrázky 2 a 3 zobrazují skutečné výstupy z n-gramové analýzy českého korpusu. Mezera má mezi unigramy nejvyšší relativní četnost, přibližně 15,1 %. N-gramy obsahující mezeru jsou významné také mezi nejčastějšími bigramy. V původním grafickém exportu se značka mezery zobrazuje jako náhradní čtvereček.



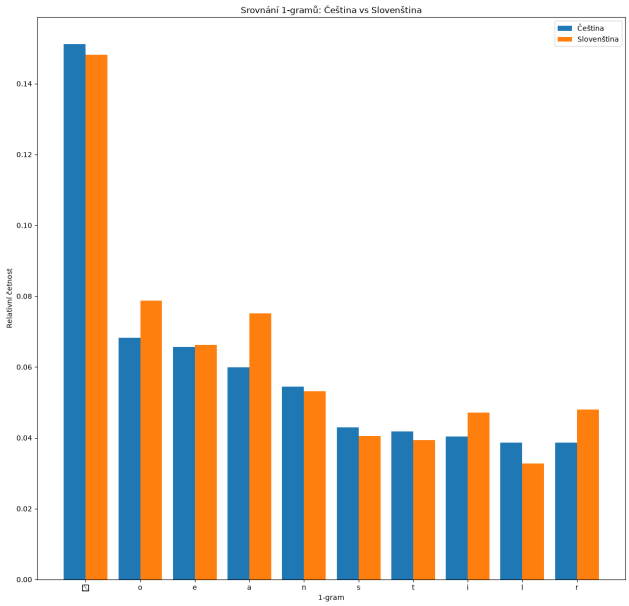
Obrázek 2: Deset nejčastějších unigramů v českém trénovacím korpusu



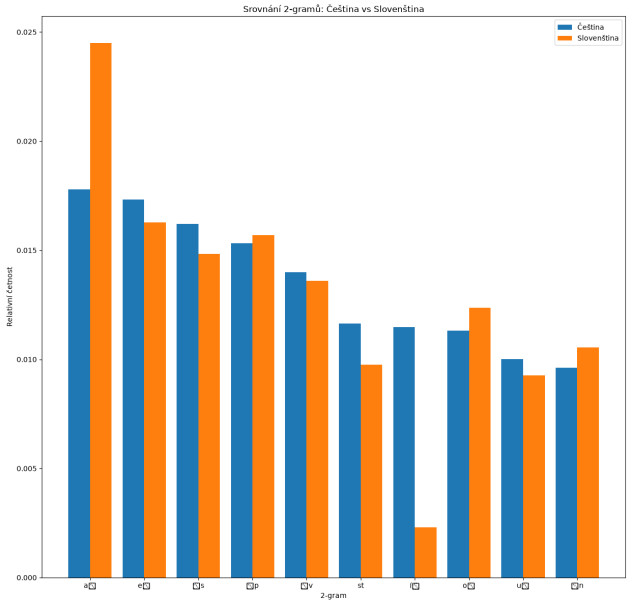
Obrázek 3: Deset nejčastějších bigramů v českém trénovacím korpusu

4.1 Porovnání češtiny a slovenštiny

Srovnávací grafy 4 a 5 pracují s totožnými n-gramy na vodorovné ose. Je patrná podobnost obou jazyků, ale také rozdíly v relativních četnostech jednotlivých znakových vzorů.



Obrázek 4: Srovnání relativních četností nejčastějších českých unigramů se slovenštinou



Obrázek 5: Srovnání relativních četností stejných bigramů v češtině a slovenštině

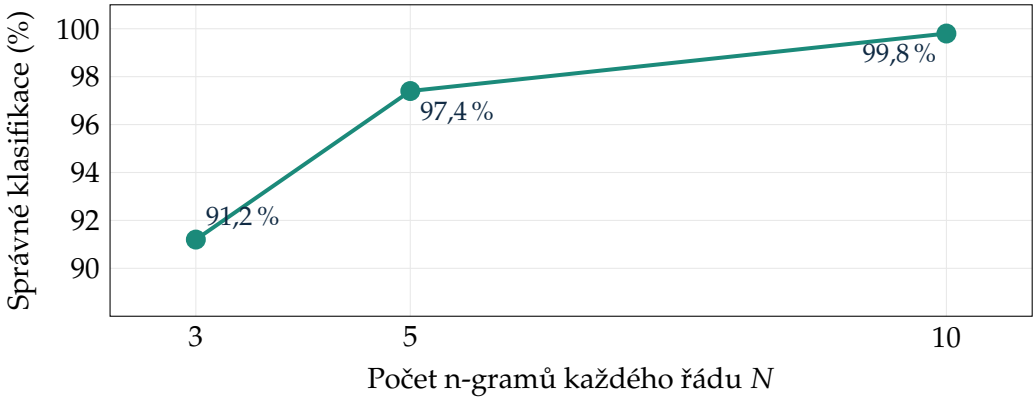
5 Experimentální vyhodnocení

5.1 Vliv počtu náhodně vybraných n-gramů

Pět vzorových vět bylo pro každou hodnotu $N \in \{3, 5, 10\}$ klasifikováno stokrát s novým náhodným výběrem. Experiment měří stabilitu na stejných větách, nikoli přesnost na nových textech.

Tabulka 2: Úspěšnost opakovaných klasifikací v procentech, pro každé N celkem 500 rozhodnutí

Jazyk	$N = 3$	$N = 5$	$N = 10$
Čeština	83	91	99
Slovenština	95	100	100
Angličtina	99	100	100
Ruština	95	100	100
Ukrajinština	84	96	100
Celkově	**91,2**	**97,4**	**99,8**



Obrázek 6: Stabilita klasifikátoru v závislosti na počtu náhodně vybíraných n-gramů

5.2 Přehled konkrétních záměn

Z původního experimentu se stejnými pěti větami lze vypsat, které jazykové dvojice model zaměňoval. Číslo v závorce udává počet chybných rozhodnutí ze 100 opakování dané věty.

Výpis chybných přiřazení

N	Skutečný → predikovaný jazyk	**Chyb**
3	CS → SK (17), SK → CS (5), EN → CS (1), RU → UK (5), UK → RU (16)	44
5	CS → SK (9), UK → RU (4)	13
10	CS → SK (1)	1

Zkratky: CS čeština, SK slovenština, EN angličtina, RU ruština, UK ukrajinština.

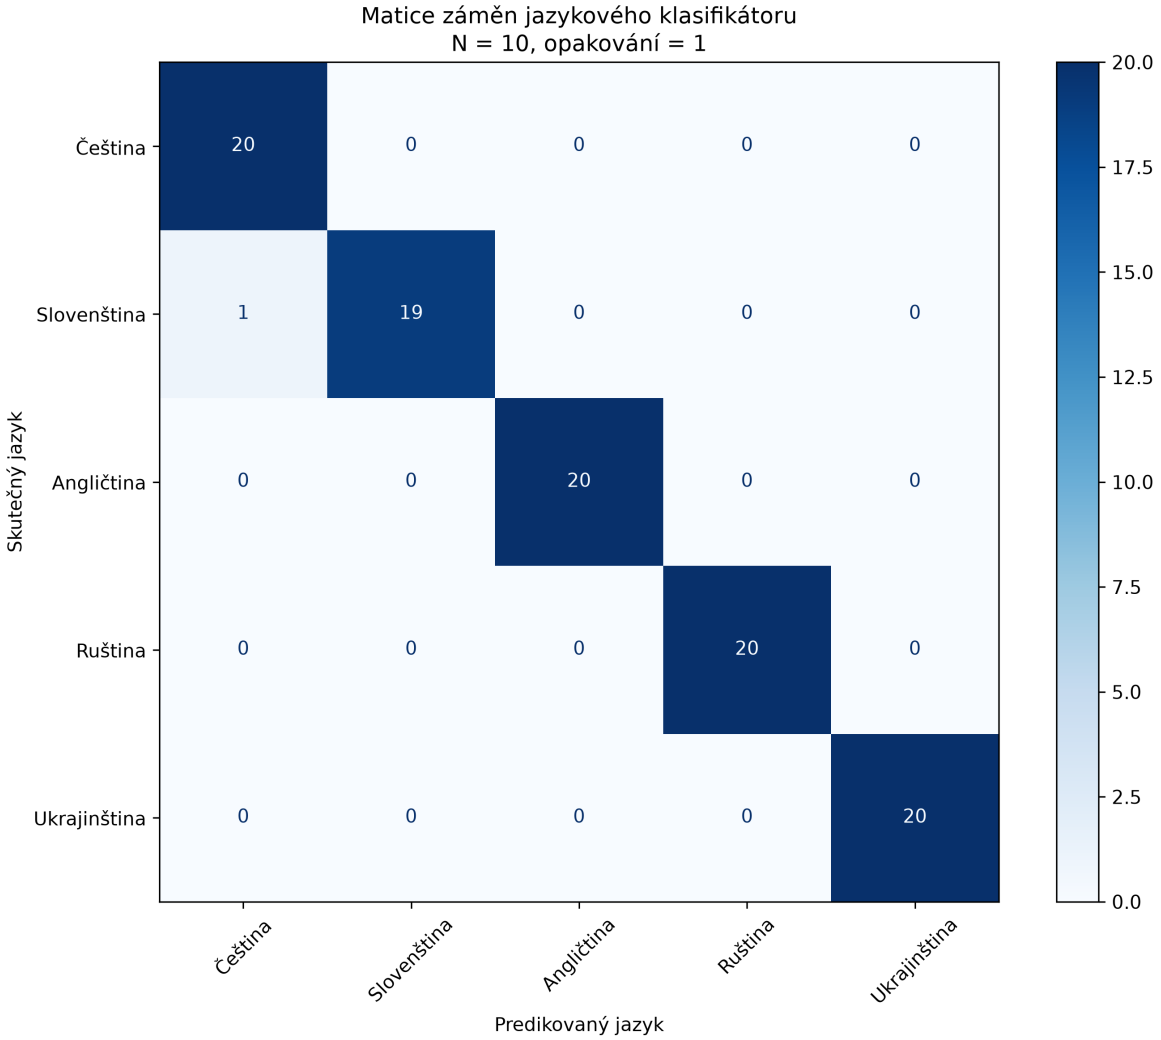
Ve sledovaném experimentu vzrostla úspěšnost z 91,2 % pro $N = 3$ na 99,8 % pro $N = 10$.

5.3 Test na 100 nových textech

Pro každý z pěti jazyků bylo získáno 20 dalších textových pasáží. Každý text byl klasifikován jednou při $N = 10$ a náhodném seedu 42. Výsledná konfuzní matice je na obrázku 7. Jediný slovenský text byl nesprávně označen za český.

Tabulka 3: Klasifikační metriky na testovací sadě, v procentech

Jazyk	Precision	Recall	F_1
Čeština	95,24	100,00	97,56
Slovenština	100,00	95,00	97,44
Angličtina	100,00	100,00	100,00
Ruština	100,00	100,00	100,00
Ukrajinština	100,00	100,00	100,00
Makroprůměr	**99,05**	**99,00**	**99,00**



Obrázek 7: Skutečná matice záměn pro 100 testovacích textů (20 na jazyk, $N = 10$)

6 Závěr

Byl vytvořen vlastní jazykový klasifikátor založený na znakových uni-, bi- a trigramech se zachováním mezer a diakritiky. Na pěti trénovacích korpusech o celkové velikosti 1,08 milionu znaků

byly odhadnuty relativní četnosti; rozhodování využívá náhodný výběr n-gramů a logaritmická skóre inspirovaná naivním Bayesovým klasifikátorem.

S rostoucím N vykazoval model vyšší stabilitu (91,2 % až 99,8 %). Na 100 dalších testovacích textech dosáhl při $N = 10$ přesnosti

$$\text{Accuracy} = \frac{\operatorname{tr}(M)}{\sum_{i,j} M_{ij}} = \frac{99}{100} = 99\,\%. \tag{6}$$

Jediná záměna nastala mezi slovenštinou a češtinou. Výsledek se vztahuje ke konkrétnímu testu: trénovací i testovací data pocházejí z Wikipedie a nebylo možné jednoznačně ověřit oddělení zdrojových článků podle ID.